


PROGRAMA DE BOLSAS DO SENAI CIMATEC

IDENTIFICAÇÃO	
INSTITUIÇÃO: Serviço Nacional de Aprendizagem Industrial SENAI DR BA	
NOME DO BOLSISTA: Rafael Guerra de Oliveira	
CPF Nº: 097.299.145-08	e-mail: rafael.g.oliveira@aln.senaicimatec.edu.br
ORIENTADOR (A): Tatiana Bezerra Rocha Nery	
TÍTULO DO PROJETO: Predição de Risco de Readmissão Hospitalar com Modelos Preditivos	
TÍTULO DO PROJETO DE PESQUISA DESENVOLVIDO PELO BOLSISTA: Desenvolvimento de Abordagem Preditiva para Readmissão Hospitalar em Pacientes de Terapia Intensiva	
RELATÓRIO TÉCNICO: () PARCIAL (X) FINAL	
PERÍODO ABRANGIDO PELO RELATÓRIO: 01/11/2025 a 31/08/2026	
PROJETO (PLANO DE TRABALHO)	
RESUMO: A readmissão hospitalar em até 30 dias após a alta é um indicador relevante de qualidade assistencial, associado ao aumento de custos e à sobrecarga dos sistemas de saúde. Este projeto teve como objetivo desenvolver um modelo preditivo para estimar o risco de readmissão em pacientes adultos internados em Unidade de Terapia Intensiva (UTI), a partir de dados clínicos da base pública MIMIC-IV. Ao longo do período da bolsa, o trabalho evoluiu de uma abordagem inicial baseada apenas em sinais vitais da admissão, com baixo poder discriminativo, para uma abordagem mais robusta, incorporando comorbidades crônicas, variáveis laboratoriais e marcadores de contexto social e de transição de cuidado (tipo de cobertura de saúde e destino na alta hospitalar). Também foi identificada e corrigida uma falha metodológica de vazamento de dados entre treino e teste, fortalecendo a confiabilidade da avaliação final. O modelo obtido (XGBoost) atingiu Área sob a Curva ROC de 0,64, reforçando a hipótese de que a readmissão hospitalar é um fenômeno multifatorial.	



METODOLOGIA:

Figura 1 - Pipeline metodológico do projeto, com destaque para a etapa de correção do vazamento de dados.




Fonte: Elaborado pelo autor

O estudo utilizou a base pública MIMIC-IV (Medical Information Mart for Intensive Care)¹, acessada mediante certificação em ética em pesquisa e credenciamento na plataforma PhysioNet. A população de estudo foi definida a partir de uma coorte de pacientes adultos internados em UTI com desfecho de alta hospitalar com sobrevivência, posteriormente refinada para pacientes sobreviventes a quadros de sepse, visando maior homogeneidade clínica. As variáveis extraídas incluíram sinais vitais das primeiras 24 horas de internação, exames laboratoriais (INR, bilirrubina, transaminases, entre outros), o Índice de Comorbidade de Charlson e, na etapa final, variáveis de contexto social e de transição de cuidado (tipo de cobertura de saúde e destino na alta hospitalar). O pré-processamento² incluiu codificação binária (*one-hot encoding*)³ de variáveis categóricas e tratamento de valores ausentes. Um ponto metodológico relevante identificado ao longo do projeto foi o vazamento de dados entre os conjuntos de treino e teste: como um mesmo paciente pode ter mais de uma internação registrada na base, uma divisão ingênua dos dados permitia que o mesmo paciente aparecesse em ambos os conjuntos, inflando artificialmente as métricas. Essa falha foi corrigida por meio de uma divisão agrupada por paciente (*GroupShuffleSplit*), garantindo que nenhum paciente estivesse presente simultaneamente em treino e teste. O modelo escolhido foi o *XGBoost*, com ponderação de classes (*scale_pos_weight*) para lidar com o desbalanceamento entre pacientes readmitidos e não readmitidos, e o limiar de decisão foi definido a partir da análise da curva precisão-*recall*, priorizando sensibilidade em função da relevância clínica de minimizar falsos negativos.



Figura 2 - Distribuição da variável alvo no dataset final (27.462 pacientes), evidenciando o desbalanceamento entre classes.




Fonte: Elaborado pelo autor

RESULTADOS PROPOSTOS / ALCANÇADOS:

A verificação de vazamento de dados revelou que 28,1% dos pacientes do conjunto de teste também estavam presentes no treino no split original, comprometendo a validade das métricas então obtidas. Após a correção, o modelo final apresentou Área sob a Curva ROC (AUC) de 0,6404 - resultado estatisticamente semelhante ao obtido antes da correção (0,6333), o que confirma que o modelo captura sinal real, e não um artefato do erro metodológico. Com o limiar ajustado para priorizar sensibilidade, o modelo atingiu sensibilidade de 76,1%, especificidade de 43,4% e precisão de 29,7% para a classe de readmitidos, refletindo o trade-off esperado ao priorizar a detecção de casos de risco. A análise de importância de variáveis destacou fatores como doença renal, destino na alta hospitalar (cuidados prolongados, hospice, unidade psiquiátrica), Índice de Charlson, idade e tipo de cobertura de saúde (Medicare) como os principais determinantes das previsões do modelo, corroborando a hipótese de que a readmissão hospitalar é fortemente influenciada por fatores sociais e de transição de cuidado, além dos aspectos estritamente fisiológicos.




Figura 3 - Trade-off entre sensibilidade (recall) e precisão em função do limiar de decisão.



Fonte: Elaborado pelo autor


Figura 4 - Matriz de confusão do modelo final no conjunto de teste (limiar = 0,44).



Fonte: Elaborado pelo autor



Figura 5 - Importância das 15 variáveis mais relevantes para o modelo (XGBoost).



Fonte: Elaborado pelo autor

CONCLUSÕES:

O projeto permitiu construir uma pipeline completa de análise preditiva em dados clínicos⁴, desde a definição da coorte até a avaliação criteriosa do modelo, incluindo a identificação e correção de uma falha metodológica de vazamento de dados - um aprendizado central do processo, que reforça a importância do rigor metodológico em pesquisas com dados de saúde. Os resultados indicam que o modelo desenvolvido possui capacidade discriminativa moderada (AUC de 0,64), ainda distante do desempenho desejável para aplicação clínica direta, mas suficiente para evidenciar que variáveis de contexto social e de transição de cuidado carregam sinal relevante, frequentemente subestimado em abordagens baseadas apenas em variáveis fisiológicas.

Como direções futuras, destacam-se: a incorporação de informações temporais mais granulares (em vez de agregações por média), a ampliação da coorte com validação incremental, a otimização de hiperparâmetros e a migração do pipeline para um ambiente de nuvem gerenciado, como o AWS SageMaker, visando maior escalabilidade e práticas de *MLOps*. O trabalho contribui para a



compreensão dos desafios envolvidos na predição de readmissão hospitalar e estabelece uma base sólida e metodologicamente validada para o desenvolvimento de modelos mais robustos.

REFERÊNCIAS BIBLIOGRÁFICAS E OUTRAS

¹JOHNSON, A. E. W. et al. MIMIC-IV, a freely accessible electronic health record dataset. Scientific Data, v. 10, 2023.

²MUSHTAQ, Sana. Data preprocessing in detail. Disponível em: <<https://developer.ibm.com/articles/data-preprocessing-in-detail/>>. Acesso em: 20 set.. 2026.

³GEEKSFORGEEEKS. One Hot Encoding in Machine Learning. Disponível em: <<https://www.geeksforgeeks.org/machine-learning/ml-one-hot-encoding/>>. Acesso em: 20 set.. 2026.

⁴SINGH, Sumit. End to End ML Pipeline: A Comprehensive Guide [Updated]. Disponível em: <<https://www.labellerr.com/blog/end-to-end-ml-pipeline/>>. Acesso em: 21 set.. 2026.

ANEXOS (se houver) (Anexar relatórios anteriores)

Anexo I - Resumo expandido "Desenvolvimento de Abordagem Preditiva para Readmissão Hospitalar em Pacientes de Terapia Intensiva", apresentado no XI SAPCT - Seminário de Avaliação de Pesquisa Científica e Tecnologia, SENAI CIMATEC (2026).



DESENVOLVIMENTO DE ABORDAGEM PREDITIVA PARA READMISSÃO HOSPITALAR EM PACIENTES DE TERAPIA INTENSIVA

Rafael Guerra de Oliveira¹; Luan Henrique Paim Santos²; André Brasil Vieira Wyzykowski³; Tatiana Barreto Rocha Nery⁴

¹ Graduando em Engenharia da Computação; Iniciação Tecnológica – CNPq; rafael.guerra@fbter.org.br

⁴ Universidade SENAI CIMATEC; Salvador - BA; tatianabr@fieb.org.br

RESUMO

A readmissão hospitalar em até 30 dias após a alta é um importante indicador de qualidade assistencial, estando associada ao aumento de custos e à sobrecarga dos sistemas de saúde. Nesse contexto, a identificação precoce do risco de readmissão é fundamental para auxiliar a conduta clínica. Este trabalho tem como objetivo desenvolver um modelo preditivo para estimar o risco de readmissão em pacientes adultos internados em unidade de terapia intensiva, utilizando dados clínicos das primeiras 24 horas de internação. Foi utilizada a base pública MIMIC-IV, acessada mediante certificação em ética e privacidade de dados, a partir da qual foram realizadas etapas de exploração, definição da população de estudo e extração de variáveis clínicas. Os testes iniciais permitiram avaliar a viabilidade da abordagem, indicando a necessidade de aprimoramento das técnicas, visando o desenvolvimento de ferramentas de apoio à decisão clínica e à melhoria da assistência em saúde.

PALAVRAS-CHAVE: readmissão hospitalar; unidade de terapia intensiva; modelo preditivo; dados clínicos.

1. INTRODUÇÃO

Esse fenômeno pode refletir tanto a complexidade dos casos clínicos quanto fragilidades no acompanhamento pós-alta, tornando essencial a identificação precoce de pacientes com maior risco de readmissão.¹

Nesse contexto, a análise de dados clínicos tem se destacado como ferramenta relevante para compreensão de desfechos hospitalares e apoio à tomada de decisão, especialmente em unidades de terapia intensiva, onde os pacientes apresentam maior gravidade.² A utilização de informações obtidas durante a internação permite identificar padrões associados à readmissão, possibilitando intervenções mais direcionadas.

Diante disso, o presente trabalho tem como objetivo desenvolver uma abordagem preditiva para estimar o risco de readmissão hospitalar em até 30 dias, a partir de dados clínicos de pacientes adultos internados em unidade de terapia intensiva no banco de dados MIMIC-IV, contribuindo para o aprimoramento da assistência em saúde.

2. METODOLOGIA

O desenvolvimento do estudo foi realizado a partir da base de dados pública MIMIC-IV (*Medical Information Mart for Intensive Care*), composta por registros clínicos anonimizados de pacientes hospitalizados. O acesso ao banco de dados foi obtido mediante processo de certificação em ética em pesquisa e privacidade de dados, seguido de credenciamento na plataforma *PhysioNet*, garantindo conformidade com as diretrizes para uso de dados sensíveis em pesquisa científica.

Inicialmente, foi realizada a exploração da estrutura do banco de dados, organizado em módulos hospitalares e de terapia intensiva, permitindo a integração de informações demográficas, clínicas e de monitoramento contínuo dos pacientes. A partir dessa análise, foi estruturada a população de estudo por meio da construção de uma coorte de pacientes adultos, considerando a primeira internação associada à permanência em UTI e com desfecho de alta hospitalar com sobrevivência. Para isso, foram integradas diferentes tabelas por meio de identificadores que permitem relacionar informações demográficas, temporais e clínicas.


Em seguida, foi definida a variável de interesse baseada na identificação de readmissões hospitalares em até 30 dias após a alta. Esse intervalo apresenta forte relação com a internação anterior, permitindo identificar possíveis falhas no cuidado ou na transição pós-alta, além de ser amplamente utilizado em estudos, o que facilita a comparação e validação dos resultados.³

Posteriormente, foram extraídas variáveis clínicas referentes às primeiras 24 horas de internação em UTI, com ênfase em sinais vitais como frequência cardíaca, pressão arterial, frequência respiratória, temperatura corporal e saturação de oxigênio. A extração foi realizada por meio de consultas estruturadas

em ambiente de computação em nuvem, utilizando a plataforma *Google BigQuery*, que possibilita o processamento eficiente de grandes volumes de dados.

A partir da organização do conjunto de dados, foi conduzido o desenvolvimento de um modelo preditivo utilizando abordagem de classificação binária. O processo seguiu as etapas clássicas de desenvolvimento de modelos de machine learning, incluindo definição do problema, coleta de dados, pré-processamento, seleção de algoritmos, treinamento e avaliação (**Figura 1**).

Figura 1 – Etapas do processo de desenvolvimento de modelos de *machine learning*.



Fonte: Adaptado de *GeeksforGeeks* (2023).⁴

Para a modelagem inicial, foi aplicada a técnica de regressão logística, sendo o desempenho avaliado por meio de métricas como acurácia, recall e área sob a curva ROC (AUC), com o objetivo de analisar a capacidade de discriminação entre pacientes com e sem readmissão.

3. RESULTADOS E CONCLUSÃO

A partir da definição da coorte de estudo e da extração de variáveis clínicas referentes às primeiras 24 horas de internação em unidade de terapia intensiva, foi possível estruturar um conjunto de dados adequado para análise do risco de readmissão hospitalar em até 30 dias. Inicialmente, realizou-se uma análise exploratória com o objetivo de compreender o comportamento das variáveis e a distribuição da população estudada, na qual foi evidenciado um desbalanceamento entre as classes, com predominância de pacientes não readmitidos, o que representa um desafio para a modelagem preditiva, uma vez que pode influenciar diretamente o desempenho dos modelos de classificação.

Figura 2 – Consulta SQL mostrando o desbalanceamento entre as classes.

<pre> SELECT readmit_30d, COUNT(*) AS total FROM 'mimic-rafael.readmission.model_dataset' GROUP BY readmit_30d </pre>	Linha	readmit_30d	total
	1	0	48027
	2	1	10253

Fonte: Elaborado pelo autor

A comparação entre pacientes readmitidos e não readmitidos indicou diferenças discretas nos sinais vitais analisados, como frequência cardíaca, pressão arterial, frequência respiratória, temperatura e saturação de oxigênio. No entanto, essas variáveis, quando agregadas por médias, apresentaram baixo poder discriminativo, não sendo suficientes para uma separação clara entre as classes.

A avaliação do modelo preditivo inicial, baseada em métricas como acurácia, recall e área sob a curva ROC (AUC), evidenciou limitações na capacidade de discriminação entre pacientes readmitidos e não readmitidos.

Esse comportamento pode ser explicado por diferentes fatores, incluindo o uso de um conjunto restrito de variáveis clínicas, a perda de informações temporais decorrente da agregação dos dados por médias e o desbalanceamento da variável alvo. Além disso, a readmissão hospitalar é um fenômeno complexo e multifatorial, influenciado por fatores clínicos, históricos e contextuais que não foram contemplados nesta etapa inicial.

Adicionalmente, os achados indicam a necessidade de refinamento na definição da coorte de estudo. A população inicialmente considerada, composta por um grande número de pacientes com diferentes condições clínicas, introduz elevada heterogeneidade nos dados, dificultando a identificação de padrões consistentes associados à readmissão hospitalar. Sob essa perspectiva, propõe-se como estratégia de aprimoramento a construção de coortes mais específicas, delimitadas por condições clínicas semelhantes, permitindo a análise de populações mais homogêneas.

A utilização de uma população mais específica, ainda que reduzida em tamanho, pode favorecer a identificação de relações mais claras entre variáveis clínicas e o desfecho de interesse. A partir dessa abordagem, torna-se possível realizar uma validação incremental do modelo, iniciando com coortes menores e progressivamente ampliando a população e a complexidade dos dados, conforme o desempenho obtido.

Dessa forma, os resultados desta etapa evidenciam que, embora a abordagem proposta seja metodologicamente viável, há necessidade de aprimoramento na modelagem e na definição da população de estudo. O processo conduzido até o momento contribui para a compreensão dos desafios envolvidos na predição de readmissão hospitalar e estabelece uma base sólida para o desenvolvimento de modelos mais robustos e aplicáveis no contexto clínico.

4. CONSIDERAÇÕES FINAIS

O presente estudo possibilitou a construção de uma *pipeline* inicial de análise de dados clínicos, desde a definição da coorte até a implementação de um modelo preditivo para estimar o risco de readmissão hospitalar em até 30 dias. As análises realizadas evidenciaram que, embora exista viabilidade na abordagem proposta, as variáveis clínicas utilizadas, especialmente quando agregadas, apresentam baixo poder discriminativo para o desfecho estudado, refletindo a complexidade multifatorial da readmissão hospitalar.

Diante disso, identificou-se a necessidade de aprimoramento metodológico, com destaque para a redefinição da coorte de estudo, visando a construção de populações mais específicas e homogêneas. Além disso, a incorporação de novas variáveis clínicas e contextuais, bem como o uso de técnicas mais robustas de modelagem e tratamento do desbalanceamento de classes, são estratégias fundamentais para obtenção de resultados mais consistentes.

Dessa forma, o estudo estabelece uma base sólida para evolução futura, orientando o desenvolvimento progressivo de modelos preditivos com maior capacidade de generalização e potencial de aplicação no apoio à tomada de decisão clínica.

5. AGRADECIMENTOS

Essa pesquisa foi realizada em parceria entre o SENAI CIMATEC e CNPq. O autor gostaria de agradecer ao CNPq, ao CIMATEC Saúde e ao Laboratório de Supercomputação.

6. REFERÊNCIAS

¹ SANSEVERINO, A. X. et al. **Fatores associados à readmissão em até 30 dias em pessoas idosas: estudo de caso-control.** Revista Brasileira de Geriatria e Gerontologia, v. 28, 1 jan. 2025.

² AGUIAR, L. M. M. et al. **Perfil de unidades de terapia intensiva adulto no Brasil: revisão sistemática de estudos observacionais.** Revista Brasileira de Terapia Intensiva, v. 33, p. 624–634, 24 jan. 2022.

³ DIAS, Bruna Moreno. **Readmissão hospitalar como indicador de qualidade.** 2015. Dissertação (Mestrado em Enfermagem Fundamental) - Escola de Enfermagem de Ribeirão Preto, Universidade de São Paulo, Ribeirão Preto, 2015. doi:10.11606/D.22.2016.tde-22122015-101155. Acesso em: 21 mar. 2026.

⁴ GEEKSFORGEEKS. **Machine Learning Models.** Disponível em: <<https://monografias.brasilecola.uol.com.br/engenharia/a-utilizacao-da-manutencao-preditiva-na-industria.htm>>. Acesso em: 18 mar. 2026.

PARTICIPAÇÃO EM EVENTOS TECNOLÓGICOS OU DE INOVAÇÃO/ PUBLICAÇÕES

Apresentação de resumo expandido no XI SAPCT - Seminário de Avaliação de Pesquisa Científica e Tecnologia, SENAI CIMATEC (2026).



CERTIFICADO

Certificamos que RAFAEL GUERRA DE OLIVEIRA participou do XI Seminário de Avaliação de Pesquisa Científica e Tecnologia e X Workshop de Integração e Capacitação em Alto Desempenho, realizado no SENAI CIMATEC, Salvador-BA, durante o período de 28/05/2026 a 29/05/2026, com carga horária de 20 horas.



Prof. Dra. Lillian Lefol Nani Guarieiro
Coordenação Geral SAPCT

Artigo aceito para publicação no SIINTEC 2026 (Simpósio de Inovação e Tecnologia) - apresentação prevista para data futura.



A PROOF OF CONCEPT FOR A SMART POWER STRIP ARCHITECTURE: BLACKOUT PREDICTION AND EQUIPMENT PROTECTION USING WEATHER DATA

Leonardo Santos Magalhães¹, Marcos Paulo Teles de Menezes Filho¹, Vinicius Sousa Fernandes¹, Rian Albert Dos Santos Dutra¹, Rafael Guerra de Oliveira¹, Fabio Fonseca Barbosa Gomes¹, Celso Barreto da Silva¹

¹ Senai Cimatec University, Computação, Salvador, Bahia, Brazil

author: Senai Cimatec University; Av. Orlando Gomes, 1845; leonardo.magalhaes@fbter.org.br

Abstract: In urban areas of socioeconomic vulnerability, electrical infrastructure instability and weather events cause frequent power outages, exacerbating energy poverty, and generating severe material losses. Although the Internet of Things (IoT) and predictive algorithms are already used to anticipate failures, these innovations remain inaccessible to low-income populations, motivating the development of an affordable solution aligned with the United Nations Sustainable Development Goals (SDGs) 7, 11, and 13. To investigate how an intelligent computational system can conceptually enable the preventive protection of sensitive equipment, this study proposes the preliminary development of a simulated smart power strip integrated into a predictive architecture. The methodology consisted of an experimental simulation using an ESP32 microcontroller for power data collection, with data processing and storage hosted on an Amazon Web Services (AWS) architecture. The user interface was coupled with meteorological APIs and the meta-llama/Llama-3.1-8B-Instruct language model, successfully simulating the issuance of blackout alerts based on the cross-referencing of climate variables. The results demonstrated the technical feasibility of real-time electrical measurement integrated with computational intelligence, highlighting how the proposed architecture has the potential to act as an efficient mechanism for asset preservation. It is concluded that demonstrating the viability of democratizing access to preventive technologies goes beyond traditional monitoring, establishing a foundational framework to promote conscious consumption, socio-technological inclusion, and energy justice for vulnerable communities.

Keywords: Artificial Intelligence. Weather Forecasting. Energy Justice. IoT Line Filter. AWS.

Abbreviations: IoT, Internet of Things. SDG, Sustainable Development Goals. UN, United Nations. LLM, Large Language Model. AWS, Amazon Web Services

1. Introduction

Accelerated urban growth and social inequalities have created a scenario where access to electrical energy is not always synonymous with quality or safety. In areas of socioeconomic vulnerability, the electrical infrastructure is often precarious, resulting in frequent oscillations and abrupt power outages, especially during weather events. This phenomenon not only exacerbates energy poverty through inefficient consumption but also causes severe material losses, such as appliance burnout, further penalizing low-income populations who lack the resources for the rapid replacement of their goods. Residential energy deprivation and technological exclusion go hand

in hand, generating a gap in the development of innovations for vulnerable populations. (Bouzarovski, S. 2015 [1]) Bridging this gap represents a critical step to mitigate energy poverty, making the act of directing intelligent systems to these areas relevant and aligning technological development as a supportive tool for the United Nations Sustainable Development Goals (SDGs), specifically SDGs 7, 11, and 13. In this sense, the application of the Internet of Things (IoT) to isolate and quantify residential consumption becomes essential. Considering that devices connected directly to outlets act as data collectors, they have been gaining ground and demonstrating their efficiency in transmitting information in real time (Al-Ali, A. 2017 [2]),

XII SIINTECINTERNATIONAL SYMPOSIUM ON
INNOVATION AND TECHNOLOGY**Currents of
the future:**ENERGY, CLIMATE,
AND GLOBAL
SUSTAINABILITY

proving to be fundamental for mapping the individual consumption of each appliance with the aim of optimizing conscious consumption strategies to combat waste (Kelly, J. 2015 [3]). The processing of these electrical consumption data, enhanced using models based on deep learning, already demonstrates its efficiency in estimating expenditure from temporal histories. The integration of these predictions into digital dashboards expands the functionality of the product compared to traditional power strips, generating predictive insights for the end consumer based on their energetic behavior (Mocanu, E. 2016 [4]). Furthermore, differentiating itself from conventional solutions, another approach explored to protect consumer goods is the prediction of power supply failures through weather correlations. The literature demonstrates that energy distribution is directly linked to meteorological factors, which can be modeled for use in predictions by artificial intelligence capable of cross-referencing these variables with the grid stability history to forecast blackouts (Eskandarpour, R. 2017 [5]). Although these models are traditionally restricted to large companies, their democratization and structural adaptation for the residential consumer constitute a promising technological pathway to support urban energy justice, foster conscious consumption, and potentially reduce waste, offering the user the necessary response time to protect their appliances against electrical surges resulting from the drop or abrupt restoration of voltage. Given the problems surrounding the

absence of accessible intelligent and predictive monitoring systems, the present project establishes the following research problem: How can the preliminary development and simulation of an intelligent computational solution, designed to integrate predictive models, establish a foundation for enable the preventive protection of appliances and promote energy justice? To bridge the gap between technology and the reality of the affected populations, the general objective of this work is to propose and validate the architecture of an accessible technological solution, composed of a smart power strip and a cloud architecture, focused on electrical consumption management and preventive protection.

2. Methodology


The experimental setup of the project was conducted entirely in a virtual simulation environment, utilizing the Wokwi platform for hardware testing as a proof of concept. The components employed were an ESP32 microcontroller for power data acquisition and transmission, functioning as the central processing unit of the smart power strip; and six potentiometers connected to the ESP32 to simulate the power oscillation behavior of each device plugged into the power strip, as shown in Figure 1. External to the circuitry, the WeatherAPI was utilized for real-time weather data acquisition. To develop the chatbot, the meta-llama/Llama-3.1-8B-Instruct Large Language Model (LLM) was integrated, which

XII INTERNATIONAL SYMPOSIUM ON INNOVATION AND TECHNOLOGY
Currents of the Future: Energy, Climate, and Global Sustainability - 2026



was also employed to simulate the predictive model. For data analysis and storage, Amazon Web Services (AWS) cloud infrastructure was utilized, comprising Amazon API Gateway to receive power data requests, Amazon Lambda for signal processing, Amazon DynamoDB for data storage, and Amazon S3 for hosting the user interface.

Figure 1. Virtual set-up environment for evaluating electrical behavior of real appliances.




Data acquisition consisted of programming the microcontroller to perform continuous measurements at thirty-second intervals. The ESP32 algorithm fixes the grid voltage at 127 Volts and, from the current variations simulated by the potentiometer, calculates the active power and consumption in kilowatt hours. After each calculation cycle, the device structures this information in JavaScript format, storing the identification of each appliance, the measurement date and time (timestamp), the electrical values, and the operational status of the outlet. This approach ensures the standardization and

integrity necessary for sending the information to the external processing stage.

The integration flow was initiated by the Amazon API Gateway, configured to receive the data requests generated by the ESP32. This gateway acts as a communication bridge to Amazon Lambda, which in turn processes the received packets, validating the integrity of the requests, calculating metrics, and inserting a timestamp to organize the measurements, as can be seen in Figure 2. To ensure the persistence of this information, Amazon DynamoDB was chosen as a non-relational database for continuous storage of the data. The records table was structured with a composite key, using the identifier of each appliance as the partition key and the measurement time as the sort of key, optimizing searches in the system's history.

Figure 2. Proposed system architecture.



XII SIINTEC

INTERNATIONAL SYMPOSIUM ON
INNOVATION AND TECHNOLOGY

Currents of
the future:

ENERGY, CLIMATE,
AND GLOBAL
SUSTAINABILITY

API, application programming interface. HTTP, hypertext transfer protocol. HTTPS, hypertext transfer protocol secure. JWT, JSON web token. UI, user interface. VPC, virtual private cloud.

A second function in Amazon Lambda was created to query the database and apply statistical calculations, to determine the average power and total consumption per appliance. For the visualization of these data by the end user, an interface was developed with the help of the Google AI Studio tool that acts as a control panel, allowing the user to view the combined or individual expenditure of each equipment, history and average, in real time, of consumption and the power outage forecast, as shown in Figure 3 to Figure 5. For the acquisition of climate data, the “WeatherAPI” API was used, which sends information about current weather conditions, such as wind speed and humidity, as well as the weather forecast, including probability of rain, cloud cover, and moon phases. In this sense, the integration of the LLM model was done through the Hugging Face Router, integrating the meta-llama/Llama-3.1-8B-Instruct model, which stands out for its optimization for chat, instructions, and support. The model acts as an assistant in monitoring energy consumption, history, and consumption goals and providing suggestions for good practices for energy saving. This same model was employed specifically as a heuristic feasibility test, serving as a structural placeholder to simulate the operational flow of a future dedicated predictive model in forecasting power supply failures resulting from climate events. At the end, the entire control panel was

hosted on Amazon S3, which communicates with the backend, allowing consumption monitoring and decision-making in real time.

3.

The development of the solution resulted in a functional prototype in a simulation environment capable of providing a preliminary validation of the proposed data flow architecture, from the collection endpoint to the final user visualization. The integration between the microcontroller and the cloud services occurred successfully, ensuring the continuous measurement of the simulated power (Figure 4) and the structured storage in a non-relational database.

Figure 3. Dashboard interface displaying real-time active power and current consumption.



Figure 4. Dashboard interface displaying the energy consumption history and the accumulated timeline of daily hardware readings.

XII SIINTEC

INTERNATIONAL SYMPOSIUM ON
INNOVATION AND TECHNOLOGY


Currents of
the future:

ENERGY, CLIMATE,
AND GLOBAL
SUSTAINABILITY



In the interface layer, the hosted control panel allowed the instant visualization of the aggregated and individual consumption of the appliances, demonstrating the technical feasibility of the acquisition and transmission of information in real time. The incorporation of the meta-llama/Llama-3.1-8B-Instruct language model, operating in conjunction with the climate data requests from the WeatherAPI interface, demonstrated the viability of the communication pipeline, generating heuristic alerts that correlates wind speed and rain probability with the theoretical risk of local supply failures (Figure 4).

Figure 5. Dashboard interface displaying the power outage prediction based on real-time climate and AI risk assessment.



In a scenario of continuous physical application, with the acquisition of a long-term empirical dataset, a quantitative validation of the gain in

energy efficiency is projected. It is theoretically expected that the uninterrupted collection of consumption data over months will allow the in-depth training of predictive models, identifying precise behavioral profiles and appliances operating with low efficiency. With the calibration of a specialized model based on a large meteorological and electrical grid stability history of a given region, the accuracy in anticipating blackouts could reach optimal levels. This future transition from simulation to field operation would allow measuring the effective reduction of consumption in kilowatt-hours and quantifying the decrease in the equipment burnout rate due to voltage surges, statistically validating the hardware protection. In the social context, the results provide a conceptual response to the established research problem, suggesting that such integrated technology has the potential to act as a supportive agent for protection and inclusion once empirically validated. The transformation of an automation and data analysis system into an accessible product aims to enable the preventive protection of sensitive equipment, theoretically mitigating losses of these products that frequently destabilize the finances of families in a situation of socioeconomic vulnerability. By alerting the user with sufficient time to turn off the appliances before voltage surges, the proposed solution goes beyond traditional electrical monitoring to act as a socioeconomic security tool. In this way, demonstrating the feasibility of the democratization of accessible computational

XII INTERNATIONAL SYMPOSIUM ON INNOVATION AND TECHNOLOGY
Currents of the Future: Energy, Climate, and Global Sustainability - 2026



XII SIINTEC

INTERNATIONAL SYMPOSIUM ON
INNOVATION AND TECHNOLOGY

Currents of the future:

ENERGY, CLIMATE,
AND GLOBAL
SUSTAINABILITY

predictability serves as a foundational step toward promoting energy justice, projecting a future where peripheral consumer regain control over their resources and are actively inserted into the scope of global sustainability goals.

4. Conclusion

The present project demonstrated the preliminary technical feasibility and highlighted the social relevance of integrating the Internet of Things and computational intelligence as conceptual instruments to combat technological exclusion and energy poverty. The developed architecture, validated in a simulation environment and supported by cloud services, proved capable of providing the user with detailed control over their electrical consumption, establishing the structural basis for an asset safeguard mechanism. By democratizing the viability of interactive monitoring dashboards and heuristic early warnings based on the cross-referencing of data with local weather, the system establishes a framework that aims to empower vulnerable populations to make preventive decisions, reducing energy waste and mitigating material losses caused by power outages and voltage surges in the grid. As the next steps for the evolution of the research, the transition from the virtual environment to the physical assembly and empirical validation of the electronic circuit is projected. For computational advancement, the training and implementation of a robust deep learning predictive model are planned, which will

replace the heuristic simulation to generate voltage surge predictions with scientifically validated accuracy and reliability. In parallel, to ensure that the innovation eventually achieves its purpose of social transformation, the project will require field studies and will seek government support aimed at obtaining grants and subsidies. This economic viability strategy is essential to reduce production costs and guarantee the dissemination of the device in vulnerable communities, consolidating the transition of this preliminary technology into a fundamental pillar for energy justice.

References

- [1] Bouzarovski S, Petrova S. *A global perspective on domestic energy deprivation: Overcoming the energy poverty–technology translation gap*. Energy Research & Social Science. 2015;10:31-40.
- [2] Al-Ali AR, Zualkernan IA, Rashid M, Gupta R, AliKarar M. *A smart home energy management system using IoT and big data analytics approach*. IEEE Transactions on Consumer Electronics. 2017;63(4):426-434.
- [3] Kelly J, Knottenbelt W. *The UK-DALE dataset, domestic appliance-level electricity demand and whole-house demand from five UK homes*. Scientific Data. 2015;2(1):1-14.
- [4] Mocanu E, Nguyen PH, Kling WL, Gibescu M. *Deep learning for estimating building energy consumption*. Sustainable Energy, Grids and Networks. 2016;6:91-99.
- [5] Eskandarpour R, Khodaei A. *Machine learning based power grid outage prediction in response to extreme events*. IEEE Transactions on Power Systems. 2017;32(4):3315-3322.

XII INTERNATIONAL SYMPOSIUM ON INNOVATION AND TECHNOLOGY
Currents of the Future: Energy, Climate, and Global Sustainability - 2026



Participação no AI Summit Brasil, 21 de maio de 2026.



OBSERVAÇÕES DO ORIENTADOR

O aluno cumpriu as atividades previstas. Atuou num tema relevante para o mercado de saúde onde estamos testando algumas POCs em parceria com HPC. De acordo com o relatório.

LOCAL: Salvador

DATA: 21/09/2026

Electronically signed by:
Tatiana Barreto Rocha Nery
CPF: ***.056.704-**
Date: 9/21/2026 1:33:46PM -03:00

SENAI

Assinatura do Orientador

Documento assinado digitalmente
gov.br RAFAEL GUERRA DE OLIVEIRA
Data: 21/09/2026 17:17:09-0300
Verifique em <https://validar.iti.gov.br>

Assinatura do (a) Bolsista





MANIFESTO DE ASSINATURAS



Código de validação: KJQNZ-CEPG7-MJYEX-NE7VW

Esse documento foi assinado pelos seguintes signatários nas datas indicadas (Fuso horário de Brasília):

- ✓ Tatiana Barreto Rocha Nery (CPF ***.056.704-**) em 21/09/2026 13:33 -
Assinado eletronicamente

Endereço IP	Geolocalização
177.181.236.78	Não disponível
Autenticação	tatianabr@fieb.org.br (Verificado)
Login	
Xw++vkYa90T4dRIsZ3fvHKUg/x6FXs1TuANIfa8uKk=	
SHA-256	

Para verificar as assinaturas, acesse o link direto de validação deste documento:

<https://assinatura.senaibahia.com.br/validate/KJQNZ-CEPG7-MJYEX-NE7VW>

Ou acesse a consulta de documentos assinados disponível no link abaixo e informe o código de validação:

<https://assinatura.senaibahia.com.br/validate>